Desenvolva algoritmos de ML de forma PROFISSIONAL

Conheça o pipeline em Python

Gabriel **Gomes**
@info_dados

arraste para o lado

O QUE É?

O conceito de "Pipeline" em aprendizado de máquina e ciência de dados, sendo uma abordagem **organizada e eficaz para processar dados e treinar modelos de forma sistemática.**

Um pipeline é uma sequência de etapas que incluem **pré-processamento de dados, transformações e modelagem, tudo em um fluxo contínuo.**

Veja exemplo SEM e COM pipeline.

SEM PIPELINE

Desenvolver as etapas necessárias para pré-processamento.

```
# IMPUTANDO VALORES NULOS PELA MEDIANA
imputer = SimpleImputer(strategy='median')
x_treino[cols_num] = imputer.fit_transform(x_treino[cols_num])
x_teste[cols_num] = imputer.transform(x_teste[cols_num])
```

```
# CONVERTENDO VARIÁVEL CATEGORICA EM OHE
encoder = OneHotEncoder()
x_treino_encoded = encoder.fit_transform(x_treino[cols_cat])
x_teste_encoded = encoder.transform(x_teste[cols_cat])
```

```
# COMBINANDO AS COLUNAS PRE-PROCESSADAS
x_treino_processed = np.hstack((x_treino_encoded.toarray(), x_treino[cols_num]))
x_teste_processed  = np.hstack((x_teste_encoded.toarray(), x_teste[cols_num]))
```

```
# NORMALIZAÇÃO DOS DADOS
scaler = StandardScaler()
x_treino_scaled = scaler.fit_transform(x_treino_processed)
x_teste_scaled  = scaler.transform(x_teste_processed)
```

SEM PIPELINE

E ao final, treinar e testar o algoritmo.

```python
# TREINANDO O MODELO
clf = RandomForestClassifier(n_estimators=100, random_state=42)
clf.fit(x_treino_scaled, y_treino)
```

```python
# FAZENDO PREVISÕES
y_pred = clf.predict(x_teste_scaled)

# AVALIANDO MODELO
accuracy = accuracy_score(y_teste, y_pred)
print(f"Acurácia do modelo: {accuracy}")
```

```
Acurácia do modelo: 0.7988826815642458
```

COM PIPELINE

Primeiro preparar o pré-processamento em cada coluna.

```
# CRIANDO COLUNAS PARA PRE-PROCESSAMENTO
preprocessor = ColumnTransformer(
    transformers=[
        # Correção de valores nulos pela mediana
        ('num', SimpleImputer(strategy='median'), cols_num),
        # Transformação de variáveis categóricas em one-hot encoding
        ('cat', OneHotEncoder(), cols_cat),
        # Normalização dos dados
        ('scaler', StandardScaler(), cols_num)
    ])
preprocessor
```

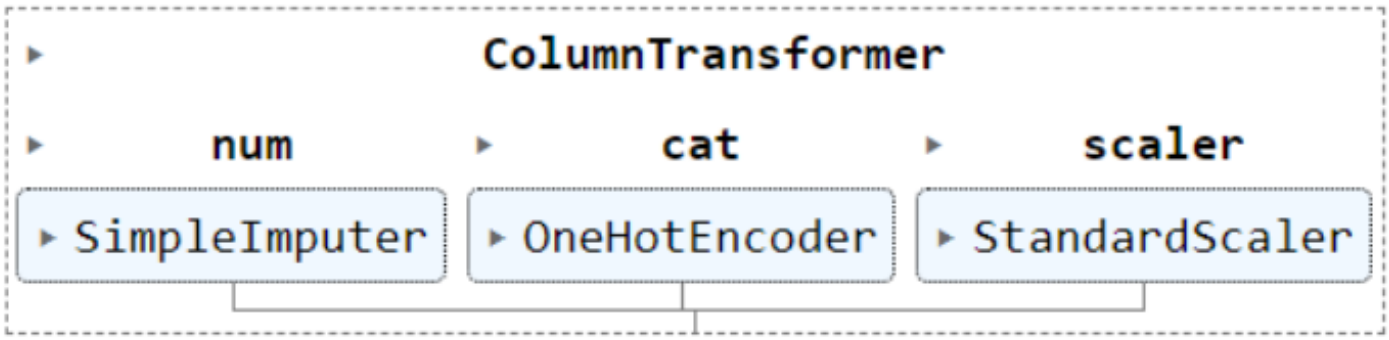

COM PIPELINE

Criar o pipeline com o pré-processamento e modelo.

```python
# CRIANDO UM PIPELINE COM PRE-PROCESSAMENTO E ALGORITMO
pipeline = Pipeline([
    ('preprocessor', preprocessor),  # Pré-processamento
    ('clf', RandomForestClassifier(n_estimators=100, random_state=42))  # Modelo
])
# TREINANDO MODELO
pipeline.fit(x_treino, y_treino)
```

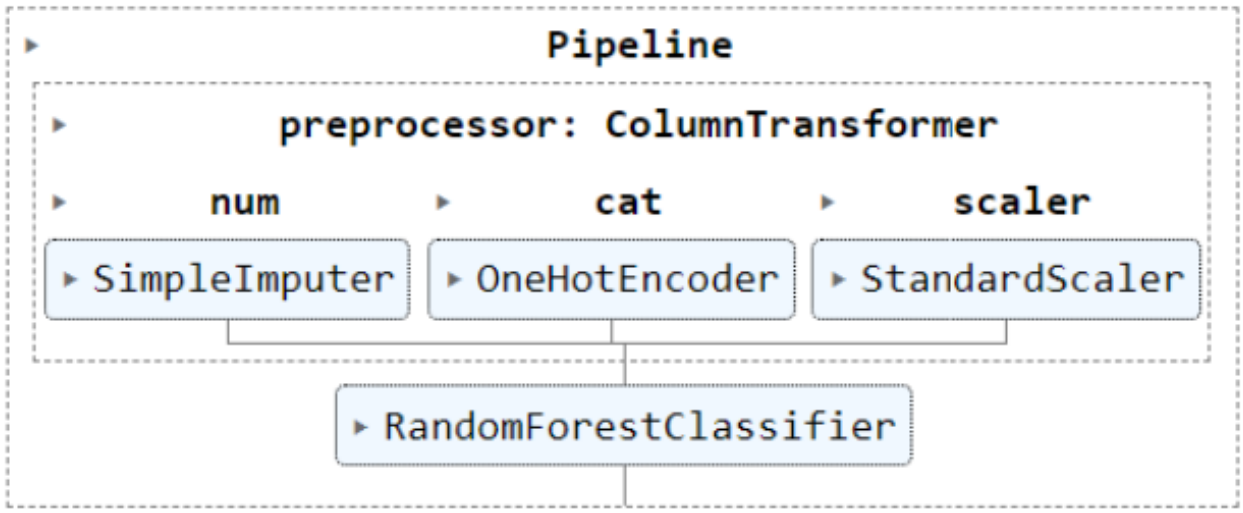

E ao final treinar e testa o algoritmo.

```python
# FAZENDO PREVISÕES
y_pred = pipeline.predict(x_teste)

# AVALIANDO MODELO
accuracy = accuracy_score(y_teste, y_pred)
print(f"Acurácia do modelo: {accuracy}")
```

```
Acurácia do modelo: 0.7988826815642458
```

VANTAGENS

1. **Organização e Clareza.**

2. **Reprodutibilidade**.

3. Prevenção de **Vazamento de Dados**(*data leakage*).

4. **Facilita** a Experimentação/Testes.

DESVANTAGENS

1. **Complexidade** em projetos mais complexos.

2. **Rigidez**.

3. **Limitações** de Personalização.

4. **Desempenho** em projetos complexos.

Gostou da dica?

Salve para testa depois!

Gabriel **Gomes**
@info_dados

INFODADOS
TRANSFORMANDO DADOS EM NEGÓCIOS